UNIVERSIDADE FEDERAL DE SANTA MARIA
CENTRO DE CIÊNCIAS RURAIS
DEPARTAMENTO DE FITOTECNIA
PROGRAMA DE PÓS-GRADUAÇÃO EM AGRONOMIA

CRISTHIAN MILBRADT BABESKI

QUESTÕES - EXAME DE QUALIFICAÇÃO DE DOUTORADO

Respostas às questões do(a) examinador(a):
Prof. Velci Queiroz de Souza (UNIPAMPA) - Membro da Banca Examinadora

Santa Maria, RS
2026

Sumário

QUESTÃO 1 - FENOTIPAGEM, AMBIENTE E INTERAÇÃO GENÓTIPO x AMBIENTE 3

1.1 FUNDAMENTAÇÃO ESTATÍSTICA: DECOMPOSIÇÃO DE VARIÂNCIA, MODELOS MISTOS E MODELAGEM DA INTERAÇÃO 3

1.2 DISTINÇÃO BIOLÓGICA ENTRE POTENCIAL GENÉTICO, EFEITO AMBIENTAL E INTERAÇÃO 5

1.3. IMPLICAÇÕES PARA A SELEÇÃO DE GENÓTIPOS DE SOJA 6

1.4 LIMITAÇÕES DE INFERIR ESTABILIDADE E ADAPTAÇÃO A PARTIR DE UM ÚNICO LOCAL E MÚLTIPLAS SAFRAS 6

2. QUESTÃO 2 - AJUSTE ESTATÍSTICO, CAPACIDADE PREDITIVA E SOBREAJUSTE 7

2.1 O QUE R^2, RMSE E MAE EFETIVAMENTE MEDEM - E POR QUE PODEM DIVERGIR 8

2.2. AJUSTE, SOBREAJUSTE E VALIDAÇÃO INTERNA 9

2.3. CALIBRAÇÃO: POR QUE UM BOM AJUSTE NÃO GARANTE CONCORDÂNCIA REAL ENTRE PREDITO E OBSERVADO 10

2.4 CRITÉRIOS DE DECISÃO: MANTER, REJEITAR OU SUBMETER À VALIDAÇÃO EXTERNA 12

3. QUESTÃO 3 - DA PREDIÇÃO FENOTÍPICA À SELEÇÃO DE GENÓTIPOS 13

3.1 POR QUE CAPACIDADE PREDITIVA NÃO EQUIVALE A VALOR DE SELEÇÃO 14

3.2 EVIDÊNCIAS ADICIONAIS PARA USO EM LINHAGENS SEGREGANTES 15

3.3 AMBIENTE, FENOLOGIA, ARQUITETURA E DOENÇAS COMO CONFUNDIDORES 15

3.4 A PROVA DEFINITIVA: GANHO DE SELEÇÃO REALIZADO 16

4. REFERÊNCIAS BIBLIOGRÁFICAS 17

QUESTÃO 1 - FENOTIPAGEM, AMBIENTE E INTERAÇÃO GENÓTIPO x AMBIENTE

Enunciado: Seu projeto propõe integrar informações fenotípicas obtidas por sensoriamento remoto, caracteres agronômicos e fitossanitários e variáveis meteorológicas, utilizando os conceitos de fenômica e ambientômica. Considerando que produtividade, teor de proteína e respostas espectrais são características influenciadas simultaneamente pelo genótipo e pelas condições ambientais, explique como você distinguiria, estatisticamente e biologicamente, uma resposta associada ao potencial genético de um genótipo de uma resposta decorrente predominantemente do ambiente ou da interação genótipo x ambiente.

Na sua resposta, discuta quais seriam as implicações dessa distinção para a seleção de genótipos de soja e explique quais limitações existem em inferir estabilidade ou adaptação de genótipos a partir dos dados obtidos em um único local experimental e em diferentes safras.

1.1 FUNDAMENTAÇÃO ESTATÍSTICA: DECOMPOSIÇÃO DE VARIÂNCIA, MODELOS MISTOS E MODELAGEM DA INTERAÇÃO

O uso de genótipos em diferentes anos no mesmo local permite distinguir o efeito ambiental da interação genótipo x ambiente (G x E), por meio da decomposição dos componentes de variância em modelos lineares mistos. Para um caráter avaliado em múltiplos genótipos e ambientes, que podem ser combinações de safras ou diferentes locais, o modelo de referência é $Yijk = \mu + Gi + Ej + (GE)ij + Bk(j) + \varepsilon ijk$, em que Gi é o efeito do genótipo i, Ej o efeito do ambiente j, (GE)ij a interação genótipo x ambiente, Bk(j) o efeito de bloco dentro do ambiente e εijk o erro experimental. Tratando genótipo, interação e ambiente como efeitos aleatórios quando possível, a estimação via REML (Máxima Verossimilhança Restrita) fornece as variâncias genética (σ^2G), ambiental (σ^2E), da interação genótipo x ambiente (σ^2GE) e residual ($\sigma^2\varepsilon$). A partir delas pode ser derivada a herdabilidade em sentido amplo na média de genótipos, $H^2 = \sigma^2G / [\sigma^2G + \sigma^2GE/e + \sigma^2\varepsilon/(re)]$, estimativa que depende do número de ambientes (e) e de repetições (r) (COELHO et al., 2021; BIANCHI et al., 2020). Ou seja, a herdabilidade não é uma propriedade fixa: conforme aumenta o número de ambientes e repetições, o erro diminui e a confiabilidade da inferência pode ser adequada, devido ao volume de genótipos amostrados em curto prazo de avaliação. Essa abordagem já foi aplicada aos dados deste projeto, nos quais a herdabilidade em sentido amplo para massa de grãos, produtividade e teor de proteína variou de 0,84 a 0,98, conforme o caráter e a safra, com acurácia seletiva

entre 0,98 e 0,99, confirmando a viabilidade do modelo misto REML-BLUP mesmo com um único local experimental.

Em avaliações conduzidas em poucos ambientes, mesmo quando se dispõe de elevado número de genótipos, a caracterização da interação G x E pode ser limitada, uma vez que a expressão fenotípica observada representa apenas uma parcela das condições ambientais às quais os genótipos podem estar submetidos. Sendo assim, a partir dos efeitos aleatórios do modelo misto, o BLUP (Best Linear Unbiased Predictor) de cada genótipo constitui o estimador de referência do valor genético, por ser corrigido pelos efeitos de ambiente, bloco e pela estrutura de variância-covariância entre as observações. Quando essa estrutura não é simples, o modelo pode incorporar estruturas de covariância adicionais. A abordagem de modelos mistos com BLUP já é empregada em ensaios de avaliação de genótipos no Brasil (COELHO et al., 2021; KEHL et al., 2022).

A literatura de melhoramento disponibiliza ainda modelos multiplicativos e de estabilidade que complementam essa análise e caracterizam melhor a natureza da interação G x E. O modelo AMMI (Additive Main Effects and Multiplicative Interaction; GAUCH, 1992) decompõe o termo de interação por $Yij = \mu + Gi + Ej + \Sigma k\ \lambda k\ \alpha ik\ \gamma jk + \theta ij$, em que Yij é a resposta do genótipo i no ambiente j, μ a média geral, Gi o efeito do genótipo, Ej o efeito do ambiente, $\Sigma k\ \lambda k\ \alpha ik\ \gamma jk$ a interação G x E decomposta em eixos multiplicativos e θij o resíduo. Os dois primeiros termos indicam qual genótipo e qual ambiente são melhores, em média; os eixos multiplicativos, visualizáveis em biplots, separam genótipos de ampla adaptação dos especificamente adaptados a um ambiente. Além disso, os modelos de Eberhart e Russell (EBERHART; RUSSELL, 1966) e de Finlay e Wilkinson (FINLAY; WILKINSON, 1963), ao regredir o desempenho de cada genótipo sobre um índice ambiental, fornecem parâmetros de inclinação (bi) e desvios de regressão (S^2di), interpretáveis como sensibilidade ambiental e previsibilidade, respectivamente. O ponto mais importante seria distinguir interação simples, em que o ranking entre genótipos se mantém entre ambientes, ou de interação complexa, em que ele se inverte; só essa última compromete de fato a validade de uma recomendação genética ampla.

Sendo assim, como este projeto já propõe integrar covariáveis ambientais de temperatura, radiação e precipitação, via NASA POWER, o passo mais informativo não é apenas detectar a interação G x E, mas explicá-la. Isso pode ser feito por regressão fatorial, relacionando os efeitos da interação às covariáveis ambientais, ou por modelos de norma de reação (COOPER; HAMMER, 1996), em que a resposta do genótipo é modelada como função

contínua de uma covariável ambiental. Essa perspectiva está alinhada a abordagens recentes de modelagem da interação G x E em trigo tropical, nas quais covariáveis ambientais são integradas a modelos fatoriais para caracterizar e predizer a resposta genotípica em diferentes condições ambientais e em ambientes não avaliados (SOUSA et al., 2026). É a lógica da ambientômica, caracterizar o ambiente pelas suas causas, como déficit hídrico, excesso de umidade e estresse térmico, e não apenas como um rótulo de local-safra, permitindo não somente medir a interação, mas também compreender os fatores ambientais associados à sua expressão.

1.2 DISTINÇÃO BIOLÓGICA ENTRE POTENCIAL GENÉTICO, EFEITO AMBIENTAL E INTERAÇÃO

Do ponto de vista biológico, o potencial genético é determinado pelos efeitos gênicos aditivos, de dominância e epistáticos, que definem a expressão do perfil de produtividade, teor de proteína e resposta espectral sob condições não limitantes, estando ligado às características do próprio genótipo. É o componente de interesse direto para o melhoramento, pois pode ser previsto nas progênies pelos princípios da genética quantitativa (XAVIER; RAINEY, 2020).

O efeito ambiental modula esse potencial em todos os genótipos, embora em intensidades diferentes: um período de déficit hídrico ou maior pressão de inóculo de doenças, por exemplo, pode reduzir a expressão do caráter em todos eles, ainda que alguns sejam mais afetados. Quando ocorre a interação G x E, a resposta difere entre os genótipos, devido à reação diferencial às condições ambientais, e genótipos com maior adaptação ou genes de tolerância sobressaem em determinadas condições. Em déficit hídrico, por exemplo, genótipos de soja podem apresentar diferenças na regulação estomática e nas respostas fotossintéticas em função da disponibilidade de água (PARASURAMAN et al., 2024). Assim, quando um genótipo apresenta maior severidade em determinado ambiente, essa observação, por si só, não permite definir a origem da diferença. Ela pode estar relacionada à maior suscetibilidade genética do genótipo, a uma condição ambiental que favoreceu a doença de maneira geral ou, ainda, a uma resposta específica daquele genótipo à condição ambiental.

Neste contexto, a resposta espectral RGB e a severidade de doenças foliares resultam da interação entre hospedeiro, patógeno e ambiente. Essa expressão da doença, que varia conforme o ambiente, pode ser caracterizada por índices funcionais aplicados às curvas de progresso de epidemias e usada na fenotipagem por imagem (DEL PONTE; DE CÓL; NARDINO, 2026). Por isso, é necessário conduzir os genótipos em anos diferentes para identificar diferenças

ocasionadas por covariáveis ambientais e, em conjunto com as notas de severidade, observar o comportamento de cada genótipo.

1.3. IMPLICAÇÕES PARA A SELEÇÃO DE GENÓTIPOS DE SOJA

As implicações para a seleção de genótipos de soja estão diretamente ligadas ao desempenho fenotípico bruto, que quando observado em um único ambiente, ele pode favorecer genótipos que tiveram vantagem apenas naquela condição, especialmente quando existe interação G x E. Em soja, estudos conduzidos em diferentes locais ou anos demonstram diferenças na classificação dos genótipos entre ambientes, evidenciando a importância de considerar essa interação durante a seleção (BIANCHI et al., 2020; KEHL et al., 2022).

Os modelos mistos e as predições BLUP permitem obter estimativas do desempenho genético dos genótipos, considerando os efeitos ambientais e experimentais. Quando diferentes ambientes são avaliados conjuntamente, modelos que incorporam explicitamente a interação G x E, como os modelos fatoriais, permitem investigar padrões de adaptação e estabilidade dos genótipos. Em soja, modelos baseados em REML/BLUP também têm sido empregados na seleção de progênies, inclusive considerando simultaneamente diferentes caracteres e ambientes (VOLPATO et al., 2019).

Nesse contexto, a fenotipagem de alto rendimento pode entrar nas etapas iniciais do melhoramento, como alternativa para diferenciar as respostas dos genótipos em ambientes ou safras específicos e como complemento às avaliações tradicionais (ALVES et al., 2024). Sua utilização para seleção genética deve, porém, considerar a repetibilidade das informações e a representatividade dos ambientes de interesse. A integração entre fenotipagem de alto rendimento, análise de imagens e inteligência artificial tem ampliado as possibilidades de obtenção e interpretação de dados para apoiar decisões em programas de melhoramento de soja (CHAGAS et al., 2026). Assim, as informações obtidas por imagens RGB podem ser utilizadas como ferramenta de triagem e caracterização fenotípica, auxiliando na identificação de genótipos de interesse.

1.4 LIMITAÇÕES DE INFERIR ESTABILIDADE E ADAPTAÇÃO A PARTIR DE UM ÚNICO LOCAL E MÚLTIPLAS SAFRAS

Uma limitação deste estudo é a avaliação dos genótipos em um único local e mesmo que em diferentes safras, ainda são poucos anos. Esse delineamento permite captar a variação temporal das condições ambientais e avaliar como os genótipos respondem a essas mudanças,

mas não contempla a variação espacial entre locais. Assim, os resultados permitem caracterizar a interação genótipo x safra nas condições avaliadas, mas não a interação genótipo x local ou a resposta dos genótipos a diferentes condições edafoclimáticas (POUR-ABOUGHADAREH et al., 2022).

No modelo adotado, os efeitos foram considerados aleatórios, permitindo estimar os componentes de variância e predizer os valores genéticos dos genótipos, considerando a variação entre safras e a interação GxE. Essa abordagem é adequada para avaliar a contribuição dessas fontes de variação e obter predições genéticas dentro dos ambientes. Em soja, modelos baseados em REML/BLUP também têm sido utilizados para avaliar genótipos em diferentes ambientes e quantificar a interação GxE (KEHL et al., 2022).

O desempenho entre as safras fornece informações sobre a resposta dos genótipos às condições observadas no local experimental, mas não deve ser interpretado como evidência de estabilidade ou ampla adaptação. A avaliação em múltiplos locais e safras é necessária para verificar se esse comportamento se mantém sob diferentes condições ambientais, sendo importante avançar para modelos de ambientômica quando houver dados de diferentes locais (ARAÚJO et al., 2025). No presente estudo, as diferenças observadas no desempenho dos grupos de maturação relativa entre as safras indicam que a resposta produtiva variou conforme as condições de cada ciclo. Esses resultados evidenciam a variação temporal da resposta dos genótipos, mas devem ser interpretados dentro das condições específicas do local avaliado.

2. QUESTÃO 2 - AJUSTE ESTATÍSTICO, CAPACIDADE PREDITIVA E SOBREAJUSTE

Enunciado: No seu projeto são propostos modelos de diferentes níveis de complexidade, desde regressões lineares até Random Forest, XGBoost e redes neurais, para predizer produtividade e severidade de doenças. Entretanto, no artigo de qualificação, os modelos utilizados para predizer a severidade das doenças apresentaram valores de R^2 bastante baixos, embora algumas predições pontuais tenham apresentado valores próximos aos observados.

Como você distingue, nesse contexto, um modelo que apresenta bom ajuste ou boas predições pontuais de um modelo que possui efetivamente capacidade preditiva e utilidade para

aplicação em fenotipagem? Quais critérios estatísticos e experimentais você utilizaria para decidir se um modelo deve ser mantido, rejeitado ou submetido à validação externa?

2.1 O QUE R^2, RMSE E MAE EFETIVAMENTE MEDEM - E POR QUE PODEM DIVERGIR

O R^2 é uma métrica relativa, normalizada pela variância observada da variável resposta ($R^2 = 1 - SQResidual/SQTotal$), enquanto RMSE e MAE expressam o erro em unidades absolutas, neste caso na própria escala de severidade, em pontos percentuais. O R^2 diz que fração da variação total entre as observações o modelo conseguiu captar; o RMSE e o MAE dizem, em pontos percentuais, o quão longe a predição fica do valor real. Quando a severidade observada varia pouco, entre 10% e 15%, por exemplo, um modelo que simplesmente preveja a média (cerca de 12,5%) para todas as parcelas já tem um erro absoluto pequeno, mas R^2 próximo de zero, pois não capturou nenhuma variação real entre elas. É exatamente isso que ocorre quando a variável resposta tem amplitude estreita, como a severidade de doenças no artigo de qualificação, cuja magnitude geral varia pouco entre alturas de voo e datas de avaliação: o erro absoluto (MAE de cerca de 2,6 pontos percentuais na mancha-alvo) é da ordem da própria severidade média (cerca de 1,6%), e a variação fina entre parcelas vizinhas é pequena e mais sensível a ruído, o que reduz o R^2 (inferior a 0,04 em todas as combinações de altura de voo e doença). Do mesmo modo, as predições pontuais próximas do observado correspondem ao cenário médio dos índices, isto é, a valores próximos da própria média da severidade, o que é esperado de um modelo com pouca capacidade de discriminar parcelas. Essa divergência entre as métricas não é uma inconsistência do modelo; é esperada estatisticamente. A literatura debate qual das duas medidas de erro é preferível (WILLMOTT; MATSUURA, 2005; CHAI; DRAXLER, 2014) e, como cada uma resume um aspecto diferente da distribuição dos erros, nenhuma deve ser usada isoladamente para caracterizar o desempenho de um modelo. O MAE (Erro Médio Absoluto) trata todos os erros da mesma forma, e o RMSE (Raiz do Erro Quadrático Médio) penaliza muito mais os erros grandes, porque eleva os valores ao quadrado antes de fazer a média.

Há ainda uma limitação específica da própria variável severidade que ajuda a explicar os R^2 baixos observados no artigo de qualificação. Notas de severidade atribuídas visualmente, mesmo quando seguem escalas diagramáticas como a de Horsfall-Barratt, não têm comportamento linear em relação à área foliar realmente doente: segundo a lei de Weber-Fechner, a percepção varia com o logaritmo do estímulo, de modo que o olho humano

discrimina melhor pequenas diferenças de severidade em níveis baixos (e, na escala de Horsfall-Barratt, também em níveis altos) do que em níveis intermediários. Isso introduz um viés de escala que nenhum modelo de regressão, por melhor ajustado que esteja, consegue corrigir sozinho. A não linearidade das curvas de progresso da doença tem implicações semelhantes para a modelagem estatística de epidemias, sobre estimativa visual de severidade discute essa imprecisão e a necessidade de cautela ao interpretar métricas de ajuste obtidas sobre esses dados (BOCK; CHIANG; DEL PONTE, 2022).

2.2. AJUSTE, SOBREAJUSTE E VALIDAÇÃO INTERNA

Um bom ajuste no treinamento não equivale a capacidade preditiva real. Na decomposição viés-variância do erro, um modelo de baixo viés e alta variância, como Random Forest ou uma rede neural, pode se ajustar quase perfeitamente aos dados de treinamento por memorizar ruído, sem generalizar para observações novas com sobreajuste. Random Forest e XGBoost, embora ambos baseados em árvores, lidam com esse equilíbrio de formas opostas. A Random Forest combina muitas árvores independentes treinadas em amostras bootstrap e reduz a variância por agregação (BREIMAN, 2001), enquanto o XGBoost constrói árvores em sequência, cada uma corrigindo o erro da anterior, e controla o sobreajuste por termos explícitos de regularização (CHEN; GUESTRIN, 2016). Na prática, o XGBoost exige ajuste mais cuidadoso de hiperparâmetros, enquanto a Random Forest é menos sensível a esse ajuste.

A exigência mínima deste estudo é avaliar o desempenho dos modelos em um conjunto de teste independente do treinamento, utilizando a partição 80/20 adotada nos Artigos 3 e 4 do projeto. Essa abordagem é complementada pela validação cruzada k-fold, que reduz a dependência de uma única divisão aleatória dos dados. Contudo, em dados coletados a campo é preciso um cuidado adicional, a validação cruzada puramente aleatória pode inflar o desempenho aparente do modelo se parcelas vizinhas do mesmo bloco forem distribuídas simultaneamente entre os conjuntos de treino e teste. Para mitigar esse efeito da autocorrelação espacial, adota-se uma validação estruturada por bloco ou por unidade de coleta independente, abordagem metodológica fundamental integrada às análises finais da tese (ROBERTS et al., 2017).

Na escolha entre modelos candidatos, quando eles são baseados em verossimilhança, como regressões lineares e modelos mistos, o Critério de Informação de Akaike penaliza o número de parâmetros por $AIC = -2 \cdot \ln(\hat{L}) + 2k$; em que $\hat{L}$ é a verossimilhança maximizada e k

é o número de parâmetros estimados. Quando o tamanho amostral (n) é pequeno em relação a k, usa-se a correção para amostras pequenas: AICc = AIC + [2k(k + 1)] / (n - k - 1); em que n é o número de observações. O termo extra tende a zero quando n é grande, e AICc converge para AIC (AKAIKE, 1974; BURNHAM; ANDERSON, 2002; HURVICH; TSAI, 1989). Quanto menor o valor, melhor o equilíbrio entre ajuste e complexidade. Para Random Forest, XGBoost e redes neurais não existe verossimilhança comparável, e a comparação deve ser feita pelo erro em dados de validação. Nos dois casos, um modelo mais complexo só se justifica se a melhora superar o custo da complexidade adicional, e não apenas por apresentar R^2 maior no treinamento.

2.3. CALIBRAÇÃO: POR QUE UM BOM AJUSTE NÃO GARANTE CONCORDÂNCIA REAL ENTRE PREDITO E OBSERVADO

Diante dessa não linearidade da própria variável severidade, discutida no item 2.1, e da capacidade de modelos mais complexos, como Random Forest e XGBoost, de captar relações não lineares entre preditores e resposta, o critério que realmente importa deixa de ser maximizar o R^2 e passa a ser garantir que as predições sejam calibradas, ou seja, que haja concordância absoluta entre valor predito e valor observado: se o modelo prevê 20% de severidade, o valor real deve estar, em média, próximo de 20%, e não distante, acima ou abaixo. Essa calibração é um aspecto crítico na validação de modelos preditivos, sendo mais informativa do que o R^2 para avaliar a acurácia das predições (VAN CALSTER et al., 2019). Para mensurá-la de forma robusta com variáveis contínuas, utiliza-se o coeficiente de concordância de Lin, que penaliza tanto a dispersão quanto o viés sistemático e a diferença de escala entre predito e observado (LIN, 1989).

Um modelo pode apresentar R^2 relativamente baixo e, ainda assim, estar bem calibrado, o que já indicaria utilidade real para a fenotipagem, como pode ser o caso dos modelos de severidade discutidos no item 2.1. Já um modelo com R^2 maior, porém mal calibrado, com viés sistemático de subestimação ou superestimação em determinada faixa de severidade, seria pouco confiável mesmo parecendo, à primeira vista, superior apenas pelo ajuste. Sendo assim, essa calibração deve ser avaliada por métricas capazes de captar a variação da severidade ao longo de todo o ciclo da cultura, e não apenas em uma única data de avaliação, já que a severidade é uma variável dinâmica e sensível à não linearidade da curva de progresso da doença discutida no item 2.1 (BOCK; CHIANG; DEL PONTE, 2022). É esse o critério que utilizo para decidir se um modelo é útil mesmo sem um R^2 elevado: não a magnitude do R^2,

mas a concordância real entre o que ele prediz e o que de fato ocorre em campo ao longo do tempo.

Na escolha entre modelos candidatos baseados em verossimilhança, como regressões lineares e modelos mistos, podem-se utilizar critérios de informação que penalizam o número de parâmetros. O Critério de Informação de Akaike (AIC) é dado por $AIC = -2 \cdot \ln(\hat{L}) + 2k$, em que $\hat{L}$ é a verossimilhança maximizada, isto é, a probabilidade de observar os dados obtidos quando os parâmetros do modelo assumem seus melhores valores; $\ln(\hat{L})$ é o seu logaritmo natural, que transforma o produto das probabilidades individuais em soma e preserva o ponto de máximo; e k é o número de parâmetros estimados, incluindo os componentes de variância (AKAIKE, 1974). O termo $-2 \cdot \ln(\hat{L})$ mede o ajuste, e quanto menor, melhor, enquanto 2k penaliza a complexidade. O Critério de Informação Bayesiano (BIC) tem a mesma estrutura, mas com penalidade maior: $BIC = -2 \cdot \ln(\hat{L}) + k \cdot \ln(n)$, em que n é o número de observações (SCHWARZ, 1978). Como $\ln(n)$ supera 2 quando $n > 7$, o BIC penaliza mais os parâmetros adicionais e tende a selecionar modelos mais simples, o que é relevante em bancos de dados grandes, nos quais o AIC tende a favorecer modelos mais complexos. Como o banco é grande, a correção para amostras pequenas (AICc) converge para o AIC e não altera a decisão (HURVICH; TSAI, 1989). No artigo de qualificação, a seleção das variáveis preditoras foi feita por regressão stepwise bidirecional com critério de p-valor ($p < 0,05$), e não por AIC, de modo que os critérios de informação aqui descritos se aplicam à comparação de modelos de verossimilhança nas análises finais da tese.

Os valores absolutos dos critérios não têm interpretação isolada, de modo que os modelos são comparados pela diferença em relação ao melhor: $\Delta AIC = AIC_i - AIC_mínimo$ (e, analogamente, ΔBIC). Para o AIC, valores de ΔAIC entre 0 e 2 indicam suporte substancial ao modelo (praticamente equivalente ao melhor), entre 4 e 7 indicam suporte consideravelmente menor, e acima de 10 indicam suporte essencialmente nulo (BURNHAM; ANDERSON, 2002). Para o BIC, ΔBIC entre 0 e 2 indica evidência fraca contra o modelo, entre 2 e 6 evidência positiva, entre 6 e 10 forte, e acima de 10 muito forte (RAFTERY, 1995). Quando vários modelos ficam com $\Delta AIC < 2$, adota-se o mais simples entre eles, pelo princípio da parcimônia. Os critérios são válidos apenas para comparar modelos ajustados aos mesmos dados e, em modelos mistos com efeitos fixos diferentes, devem ser calculados com máxima verossimilhança (ML) e não com REML.

Para Random Forest e XGBoost não há verossimilhança nem número de parâmetros (k) bem definidos, pois esses algoritmos minimizam uma função de perda e não maximizam uma

verossimilhança, de modo que o AIC não se aplica. A comparação é feita pelo erro de predição em dados não usados no ajuste, por RMSE, MAE e R^2 de validação (CHAI; DRAXLER, 2014). A validação deve respeitar a estrutura dos dados, agrupando as observações por genótipo (ou por ano) nas partições, de modo que o conjunto de teste contenha genótipos (ou anos) não vistos no ajuste, evitando vazamento de informação e superestimação do desempenho (ROBERTS et al., 2017). Esse mesmo critério pode ser aplicado aos modelos lineares e mistos, permitindo compará-los diretamente com os de aprendizado de máquina. Nas análises finais da tese, todos os modelos serão avaliados no mesmo banco e nas mesmas partições, com as métricas reportadas pela média e pelo desvio-padrão entre elas, de modo que diferenças menores que a variação entre partições não sejam interpretadas como superioridade de um modelo. Como medida de sobreajuste, será usada a diferença entre o erro de treino e o de validação e, entre modelos de desempenho semelhante, será adotado o mais simples. Em ambos os casos, um modelo mais complexo só se justifica se a melhora superar o custo da complexidade adicional, e não apenas por apresentar R^2 maior no treinamento.

2.4 CRITÉRIOS DE DECISÃO: MANTER, REJEITAR OU SUBMETER À VALIDAÇÃO EXTERNA

Hierarquia metodológica de decisão: de seleção a validação externa

Para organizar esses critérios, trato a decisão como uma hierarquia de quatro etapas, cada uma mais exigente que a anterior, em linha com os esquemas de validação de rigor crescente descritos na literatura de predição aplicada ao melhoramento (FRITSCHE-NETO et al., 2025):

a) Seleção: comparação entre modelos candidatos de diferentes complexidades.
- AIC ou AICc entre os modelos baseados em verossimilhança, e erro de validação entre os demais.
- Confronto obrigatório com um modelo de referência simples: a média da severidade, ou a regressão do índice espectral mais correlacionado.
- Escolha orientada por parcimônia, e não apenas por ajuste bruto ao treinamento.

b) Validação interna: diagnóstico de generalização dentro do próprio experimento.
- Validação cruzada k-fold, com intervalo de confiança empírico para R^2, RMSE e MAE.
- Validação cruzada espacial (leave-one-block-out ou leave-one-flight-out) quando há autocorrelação entre parcelas vizinhas (ROBERTS et al., 2017).
- Análise de resíduos por faixa de severidade, altura de voo e data de avaliação, para checar heterocedasticidade e viés sistemático.

c) Teste independente: confirmação em dados nunca usados no ajuste.
- Avaliação na partição de teste (80/20) já adotada neste projeto.

- Verificação da calibração (coeficiente de concordância de Lin), e não apenas do R^2.
- Estabilidade do desempenho entre condições já manipuladas no experimento: alturas de voo, datas de avaliação e as três doenças avaliadas.

d) Validação externa**:** confirmação fora das condições em que o modelo foi construído, em rigor crescente.

- Validação temporal: nova safra, mesmo local.
- Validação espacial: novo local.
- Validação genética: novo painel de genótipos ou população segregante. É a etapa mais exigente e a mais ligada ao objetivo de seleção desta tese, pois testa a condição de uso pretendida: genótipos que o modelo ainda não viu.

Um modelo só avança de uma etapa para a seguinte quando cumpre integralmente a anterior. Ele deve ser mantido quando supera de forma consistente a referência simples, apresenta resíduos sem viés relevante nas faixas de interesse e desempenho estável entre as condições do experimento, ainda que o R^2 permaneça modesto, desde que a discriminação seja satisfatória e a calibração boa.

O modelo é descartado quando não supera o referencial básico, apresenta viés sistemático relevante ou tem desempenho que depende criticamente de uma altura de voo ou data específica, falhando em generalizar entre elas. Ele deve ser encaminhado à validação externa exatamente quando os critérios internos forem cumpridos, porque desempenho satisfatório dentro do próprio experimento é condição necessária, mas não suficiente (FRITSCHE-NETO et al., 2025). Para fenotipagem por imagens RGB em soja, o modelo só é considerado efetivamente útil se mantiver desempenho comparável em validações temporal e espacial. Esse é um limite reconhecido na literatura. Segundo Bai et al. (2022), que estimaram parâmetros de produtividade da soja por imagens RGB de VANT em uma única safra e um único local, apontam que o desempenho em múltiplos anos e áreas é um indicador importante da estabilidade do modelo.

3. QUESTÃO 3 - DA PREDIÇÃO FENOTÍPICA À SELEÇÃO DE GENÓTIPOS

Enunciado: O objetivo final declarado no seu projeto é utilizar a fenotipagem de alto rendimento como ferramenta para apoiar a seleção precoce de genótipos superiores de soja. Entretanto, uma variável espectral ou uma fotografia de folíolo constitui uma medida indireta, e não uma medida direta do valor genético para produtividade.

Imagine que um modelo desenvolvido a partir de índices RGB ou fotografias de folíolos apresente elevada capacidade preditiva da produtividade dentro do conjunto experimental e

mantenha desempenho satisfatório em um conjunto externo de cultivares. Quais evidências adicionais seriam necessárias para que você pudesse afirmar que essa ferramenta é realmente útil para seleção genética de linhagens segregantes? Discuta, particularmente, os riscos de selecionar uma linhagem com elevada produtividade predita quando essa predição pode estar refletindo o ambiente, o estádio fenológico, a arquitetura da planta ou efeitos associados às doenças, e não necessariamente seu potencial genético.

3.1 POR QUE CAPACIDADE PREDITIVA NÃO EQUIVALE A VALOR DE SELEÇÃO

O índice espectral calculado a partir das bandas do vermelho, verde e azul (RGB, do inglês red, green, blue) e a produtividade de grãos são caracteres geneticamente distintos, sendo o índice o caráter secundário (x) e a produtividade, o caráter-alvo (y). Na teoria de seleção indireta, a eficiência de selecionar por x em vez de selecionar diretamente em y é a razão entre a resposta correlacionada em y (CRy) e a resposta direta em y (Ry): $CRy/Ry = (hx/hy)\cdot rg$, assumindo-se a mesma intensidade de seleção nos dois casos (FALCONER; MACKAY, 1996). Na formulação original, h é a raiz da herdabilidade no sentido restrito ($h^2 = \sigma^2A/\sigma^2P$) e rg é a correlação genética aditiva, o que exige genealogia ou matriz de parentesco para separar a variância aditiva (σ^2A). Como este trabalho não dispõe de genealogia nem de matriz de parentesco, a herdabilidade estimada é a de sentido amplo ($H^2 = \sigma^2G/\sigma^2P$) e a correlação a ser estimada é a genotípica (rG), obtida dos componentes de variância e covariância genotípicos. Essas estimativas descrevem o desempenho genotípico total, incluindo efeitos não aditivos, e não o valor genético aditivo de cada genótipo. Assim, o índice prediz o desempenho do genótipo avaliado, mas não seu potencial como genitor, e a razão CRy/Ry é uma aproximação, não o ganho esperado da seleção. Nessa aproximação, a seleção pelo índice supera a seleção direta quando $rG > Hy/Hx$, em que Hx e Hy são as raízes de H^2 de x e de y. Por isso, o índice RGB é usado como caráter auxiliar para descartar, nas fases iniciais, genótipos de baixo potencial produtivo, e não substitui a seleção direta para produtividade, que decide nos ensaios finais.

Além disso, o que importa para a seleção é a correlação genotípica (rG), e não a correlação entre o valor predito e a produtividade observada, que mistura efeito de genótipo e de ambiente. Para a seleção indireta compensar, o índice precisa ter herdabilidade alta e correlação genotípica forte com a produtividade, como se discute para a fenotipagem de alto rendimento em geral e em trigo tropical com índices de VANT em particular (ARAUS et al., 2018; MACHADO E SILVA et al., 2024). Mesmo com correlação genotípica moderada, o índice pode valer a pena se permitir avaliar mais linhagens ou selecionar mais cedo, porque o

ganho por ano depende também da intensidade de seleção e da duração do ciclo de seleção (FALCONER; MACKAY, 1996).

3.2 EVIDÊNCIAS ADICIONAIS PARA USO EM LINHAGENS SEGREGANTES

A primeira evidência seria estimar a rG entre o índice RGB e a produtividade com um modelo misto bivariado, em ensaios replicados com vários locais e safras. Assim a covariância entre os dois caracteres é separada em parte genética e parte ambiental, o que a correlação simples não faz. Abordagens multicaráter com variáveis secundárias de fenotipagem têm sido usadas justamente para isso em trigo (RUTKOSKI et al., 2016; CRAIN et al., 2018).

Seria preciso mostrar também que essa relação se mantém em populações segregantes, e não só em cultivares comerciais. Cultivares são mais homogêneas em ciclo, porte e resposta espectral, então um modelo validado nelas pode nunca ter encontrado a variação que gera os confundidores em uma geração F2 a F5. Validar em genótipos ou ambientes novos é bem mais exigente do que validar dentro do conjunto conhecido (FRITSCHE-NETO et al., 2025), e é essa a condição de uso pretendida, para verificar a aplicabilidade nas linhagens com dados de produtividade gerados. Quando há poucas safras, o número de voos pode ser incorporado ao modelo como repetição dentro da safra, mas não substitui os anos: os voos repetem a medição no mesmo ambiente e reduzem apenas o erro específico de cada voo, sem amostrar novos ambientes nem permitir estimar a interação genótipo x ano.

3.3 AMBIENTE, FENOLOGIA, ARQUITETURA E DOENÇAS COMO CONFUNDIDORES

No ambiente, mesmo dentro de um ensaio há variação de solo, água e posição no bloco, e uma parcela favorecida mostra mais vigor e mais produtividade sem ser geneticamente melhor. O modelo passaria a reconhecer boa parcela, e não bom genótipo, o que se reduz com um modelo misto que inclua a estrutura espacial do ensaio. Na fenologia, genótipos de ciclos diferentes fotografados na mesma data estão em estádios diferentes, e o mais precoce pode parecer menos vigoroso só por estar mais perto da maturação. Na arquitetura, o sensor vê o dossel por cima, então plantas mais abertas parecem mais cobertas e plantas eretas, muitas vezes desejáveis, podem ser subestimadas. Um escore de arquitetura e a altura de planta como covariáveis reduzem esse viés. Nas doenças, o índice reflete em parte o efeito de mancha-alvo,

oídio e mancha olho-de-rã sobre a folha, e a correlação com a produtividade pode estar medindo tolerância e não vigor produtivo. Incluir a severidade, que já é medida no projeto, permite separar as duas vias, e saber quanto da predição vem de cada uma já é uma informação útil para o melhorista (ARAUS et al., 2018).

Para checar se o índice continua informativo depois de controlar esses fatores, uso correlação parcial ou modelos multivariados. Se a associação cai muito, o poder preditivo vinha do confundidor e não de um sinal genético. A correlação parcial tem um limite: ela não separa confundidor de mediador, como uma arquitetura geneticamente determinada que afeta legitimamente o índice e o rendimento. Alguns autores trabalham com análise de trilha (path analysis), que permite definir um modelo causal com base agronômica e separar efeitos diretos e indiretos (CRUZ; REGAZZI; CARNEIRO, 2012).

3.4 A PROVA DEFINITIVA: GANHO DE SELEÇÃO REALIZADO

A evidência mais conclusiva é o ganho de seleção realizado, e usar o índice como critério de seleção em uma geração de população segregante, avançar as linhagens selecionadas e comparar, em gerações e ambientes seguintes, sua produtividade medida diretamente com a de linhagens não selecionadas ou selecionadas pelo critério tradicional. Esse desenho testa de uma vez a herdabilidade do índice, a correlação genética e o efeito dos confundidores que sobraram, sem depender de pressupostos do modelo estatístico (FALCONER; MACKAY, 1996).

Na tese, podemos ainda combinar os índices RGB com covariáveis ambientais no mesmo modelo genético dos ambientes, para atribuir a variação a genótipo, ambiente e doença, em vez de tratar a predição como um problema de aprendizado de máquina isolado da genética quantitativa (FRITSCHE-NETO et al., 2025).

4. REFERÊNCIAS BIBLIOGRÁFICAS

AKAIKE, H. A new look at the statistical model identification. IEEE Transactions on Automatic Control, v. 19, n. 6, p. 716-723, 1974. DOI: https://doi.org/10.1109/TAC.1974.1100705.

ALVES, A. K. S.; ARAÚJO, M. S.; CHAVES, S. F. S.; DIAS, L. A. S.; CORRÊDO, L. P.; PESSOA, G. G. F. A.; BEZERRA, A. R. G. High throughput phenotyping in soybean breeding using RGB image vegetation indices based on drone. Scientific Reports, v. 14, art. 32055, 2024. DOI: https://doi.org/10.1038/s41598-024-83807-4.

ARAÚJO, M. S.; PAVAN, J. P. S.; STELLA, A. A.; FREGONEZI, B. F.; LIMA, N. F.; LELES, E. P.; SANTOS, M. F.; GOLDSMITH, P.; CHIGEZA, G.; DIERS, B. W.; PINHEIRO, J. B. Optimizing soybean variety selection for the Pan-African Trial network using factor analytic models and envirotyping. Frontiers in Plant Science, v. 16, art. 1594736, 2025. DOI: https://doi.org/10.3389/fpls.2025.1594736.

ARAUS, J. L.; KEFAUVER, S. C.; ZAMAN-ALLAH, M.; OLSEN, M. S.; CAIRNS, J. E. Translating high-throughput phenotyping into genetic gain. Trends in Plant Science, v. 23, n. 5, p. 451-466, 2018. DOI: https://doi.org/10.1016/j.tplants.2018.02.001.

BAI, D.; LI, D.; ZHAO, C.; WANG, Z.; SHAO, M.; GUO, B.; LIU, Y.; WANG, Q.; LI, J.; GUO, S.; WANG, R.; LI, Y.; QIU, L.; JIN, X. Estimation of soybean yield parameters under lodging conditions using RGB information from unmanned aerial vehicles. Frontiers in Plant Science, v. 13, art. 1012293, 2022. DOI: https://doi.org/10.3389/fpls.2022.1012293.

BIANCHI, M. C.; BRUZI, A. T.; SOARES, I. O.; RIBEIRO, F. O.; GESTEIRA, G. S. Heritability and the genotype × environment interaction in soybean. Agrosystems, Geosciences & Environment, v. 3, n. 1, art. e20020, 2020. DOI: https://doi.org/10.1002/agg2.20020.

BOCK, C. H.; CHIANG, K.-S.; DEL PONTE, E. M. Plant disease severity estimated visually: a century of research, best practices, and opportunities for improving methods and practice to maximize accuracy. Tropical Plant Pathology, v. 47, p. 25-42, 2022. DOI: https://doi.org/10.1007/s40858-021-00439-z.

BREIMAN, L. Random forests. Machine Learning, v. 45, n. 1, p. 5-32, 2001. DOI: https://doi.org/10.1023/A:1010933404324.

BURNHAM, K. P.; ANDERSON, D. R. Model selection and multimodel inference: a practical information-theoretic approach. 2. ed. New York: Springer, 2002. DOI: https://doi.org/10.1007/b97636.

CHAGAS, J. T. B.; ARAÚJO, M. S.; PAVAN, J. P. S.; FRANÇANI, A. O.; FERREIRA, G. N. C.; STELLA, A. A.; MARTINEZ, M.; RETORE, Y. I.; FREGONEZI, B. F.; MARTINS, G. M.; ZHAO, T.; ZHOU, J.; SOUSA, D. R.; GAO, Y.; JI, D.; GAO, K.; LI, B.; LIU, S.; ZHAO, L.; PINHEIRO, J. B. Harnessing high-throughput phenotyping and artificial intelligence for soybean breeding: from trait assessment to data-driven decisions. Plant Phenomics, art. 100259, 2026. DOI: https://doi.org/10.1016/j.plaphe.2026.100259.

CHAI, T.; DRAXLER, R. R. Root mean square error (RMSE) or mean absolute error (MAE)? Arguments against avoiding RMSE in the literature. Geoscientific Model Development, v. 7, n. 3, p. 1247-1250, 2014. DOI: https://doi.org/10.5194/gmd-7-1247-2014.

CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22., 2016, San Francisco. Proceedings [...]. New York: ACM, 2016. p. 785-794. DOI: https://doi.org/10.1145/2939672.2939785.

COELHO, J. S. P.; ALVES, R. S.; PEIXOTO, M. A.; RESENDE, M. D. V.; TEODORO, P. E.; SILVA, F. L.; BHERING, L. L. Produtividade, estabilidade e adaptabilidade da soja por meio de metodologia de modelo misto. Ciência Rural, v. 51, n. 2, art. e20200406, 2021. DOI: https://doi.org/10.1590/0103-8478cr20200406.

COOPER, M.; HAMMER, G. L. (ed.). Plant adaptation and crop improvement. Wallingford: CAB International, 1996.

CRAIN, J.; MONDAL, S.; RUTKOSKI, J.; SINGH, R. P.; POLAND, J. Combining high-throughput phenotyping and genomic information to increase prediction and selection accuracy in wheat breeding. The Plant Genome, v. 11, n. 1, art. 170043, 2018. DOI: https://doi.org/10.3835/plantgenome2017.05.0043.

CRUZ, C. D.; REGAZZI, A. J.; CARNEIRO, P. C. S. Modelos biométricos aplicados ao melhoramento genético. 4. ed. Viçosa, MG: UFV, 2012. v. 1.

DEL PONTE, E. M.; DE CÓL, M. C.; NARDINO, M. A functional instability index for plant disease epidemic curves with applications to host resistance across environments. agriRxiv, 2026. Preprint. DOI: https://doi.org/10.31220/agriRxiv.2026.00450.

EBERHART, S. A.; RUSSELL, W. A. Stability parameters for comparing varieties. Crop Science, v. 6, n. 1, p. 36-40, 1966.

FALCONER, D. S.; MACKAY, T. F. C. Introduction to quantitative genetics. 4. ed. Harlow: Longman, 1996.

FINLAY, K. W.; WILKINSON, G. N. The analysis of adaptation in a plant-breeding programme. Australian Journal of Agricultural Research, v. 14, n. 6, p. 742-754, 1963. DOI: https://doi.org/10.1071/AR9630742.

FRITSCHE-NETO, R.; RESENDE, R. T.; OLIVOTO, T.; ABADILLO VELASCO, J. G.; NASCIMENTO, M.; BAHIA, M. A. M.; JARQUIN, D.; VIEIRA, R. A. Prediction-based breeding: modern tools to optimize and reshape programs. Crop Science, v. 65, n. 5, art. e70175, 2025. DOI: https://doi.org/10.1002/csc2.70175.

GAUCH, H. G. Statistical analysis of regional yield trials: AMMI analysis of factorial designs. Amsterdam: Elsevier, 1992.

HURVICH, C. M.; TSAI, C.-L. Regression and time series model selection in small samples. Biometrika, v. 76, n. 2, p. 297-307, 1989. DOI: https://doi.org/10.1093/biomet/76.2.297.

KEHL, K.; CARVALHO, I. R.; SACON, D.; RIZZARDI, M. A.; LANGARO, N. C.; LORO, M. V.; MOURA, N. B.; LAUTENCHLEGER, F. Posicionamento estratégico da soja com base no ideótipo agronômico e nos modelos multivariados fixos e mistos. Pesquisa Agropecuária Brasileira, v. 57, art. e02702, 2022. DOI: https://doi.org/10.1590/S1678-3921.pab2022.v57.27087.

LIN, L. I.-K. A concordance correlation coefficient to evaluate reproducibility. Biometrics, v. 45, n. 1, p. 255-268, 1989. DOI: https://doi.org/10.2307/2532051.

MACHADO E SILVA, C.; MEZZOMO, H. C.; RIBEIRO, J. P. O.; SIGNORINI, V. S.; LIMA, G. W.; VIEIRA, E. F. T.; PORTES, M. F.; MOROTA, G.; CORREDO, L. P.; NARDINO, M. Insights on multi-spectral vegetation indices derived from UAV-based high-throughput phenotyping for indirect selection in tropical wheat breeding. Euphytica, v. 220, n. 3, art. 35, 2024. DOI: https://doi.org/10.1007/s10681-024-03299-1.

PARASURAMAN, B.; RAJAMANICKAM, V.; RATHINAVELU, S.; GEETHANJALI, S.; ALAGARSWAMY, S. Interactive effect of drought and high temperature on physiological traits of soybean (Glycine max). Plant Physiology Reports, v. 29, n. 1, p. 116-124, 2024. DOI: https://doi.org/10.1007/s40502-023-00767-z.

POUR-ABOUGHADAREH, A.; KHALILI, M.; POCZAI, P.; OLIVOTO, T. Stability indices to deciphering the genotype-by-environment interaction (GEI) effect: an applicable review for use in plant breeding programs. Plants, v. 11, n. 3, art. 414, 2022. DOI: https://doi.org/10.3390/plants11030414.

RAFTERY, A. E. Bayesian model selection in social research. Sociological Methodology, v. 25, p. 111-163, 1995. DOI: https://doi.org/10.2307/271063.

ROBERTS, D. R.; BAHN, V.; CIUTI, S.; BOYCE, M. S.; ELITH, J.; GUILLERA-ARROITA, G.; HAUENSTEIN, S.; LAHOZ-MONFORT, J. J.; SCHRÖDER, B.; THUILLER, W.; WARTON, D. I.; WINTLE, B. A.; HARTIG, F.; DORMANN, C. F. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. Ecography, v. 40, n. 8, p. 913-929, 2017. DOI: https://doi.org/10.1111/ecog.02881.

RUTKOSKI, J.; POLAND, J.; MONDAL, S.; AUTRIQUE, E.; PÉREZ, L. G.; CROSSA, J.; REYNOLDS, M.; SINGH, R. Canopy temperature and vegetation indices from high-throughput phenotyping improve accuracy of pedigree and genomic selection for grain yield in wheat. G3: Genes, Genomes, Genetics, v. 6, n. 9, p. 2799-2808, 2016. DOI: https://doi.org/10.1534/g3.116.032888.

SCHWARZ, G. Estimating the dimension of a model. The Annals of Statistics, v. 6, n. 2, p. 461-464, 1978.

SOUSA, J. M. A.; BLASQUES, G. M.; CONDÉ, A. T.; SILVA, A. F.; EIDES, J. R.; FRONZA, R. T. L.; FERNANDES, S. B.; CARNEIRO, P. C. S.; BHERING, L. L.; NARDINO, M.; DIAS, K. O. G. Modeling genotype-by-environment interaction for variety recommendation in tropical wheat. Crop Science, 2026. DOI: https://doi.org/10.1002/csc2.70309.

VAN CALSTER, B.; MCLERNON, D. J.; VAN SMEDEN, M.; WYNANTS, L.; STEYERBERG, E. W. Calibration: the Achilles heel of predictive analytics. BMC Medicine, v. 17, art. 230, 2019. DOI: https://doi.org/10.1186/s12916-019-1466-7.

VOLPATO, L.; ALVES, R. S.; TEODORO, P. E.; RESENDE, M. D. V.; NASCIMENTO, M.; NASCIMENTO, A. C. C.; LUDKE, W. H.; SILVA, F. L.; BORÉM, A.; LIGHTFOOT, D. A. Multi-trait multi-environment models in the genetic selection of segregating soybean progeny. PLOS ONE, v. 14, n. 4, art. e0215315, 2019. DOI: https://doi.org/10.1371/journal.pone.0215315.

WILLMOTT, C. J.; MATSUURA, K. Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. Climate Research, v. 30, n. 1, p. 79-82, 2005. DOI: https://doi.org/10.3354/cr030079.

XAVIER, A.; RAINEY, K. M. Quantitative genomic dissection of soybean yield components. G3: Genes, Genomes, Genetics, v. 10, n. 2, p. 665-675, 2020. DOI: https://doi.org/10.1534/g3.119.400896.